



VERİ ANALİTİĞİ BİTİRME PROJESİ RAPORU

PARİS AIRBNB İLANLARINDA GECELİK FİYAT TAHMİNİ

Regresyon Modelleri, Aykırı Değer Analizi ve Overfitting Kontrolü ile Karşılaştırmalı Bir Uygulama

Feyza Nur Demirbaş

4. Dönem 2. Grup, 2026
SoftITo Yazılım Bilişim Akademisi

İÇİNDEKİLER

1. Giriş

1.1. Problem ve Motivasyon

1.2. Projenin Amacı

1.3. Hipotezler

1.4. Çalışmada Kullanılan Yöntemler

1.5. Araştırma Soruları

2. Literatür Taraması

2.1. Airbnb Fiyat Belirleyicileri

2.2. Makine Öğrenmesi ile Fiyat Tahmini

2.3. Aykırı Değer ve Genelleme Problemi

2.4. Literatürün Projeye Yansıması

3. Veri Kaynağı ve Materyal

3.1. Veri Seti

3.2. Kullanılan Değişkenler

3.3. Kullanılan Teknolojiler

4. Yöntem

4.1. Veri Temizleme ve Eksik Değerler

4.2. Aykırı Değer Analizi

4.3. Eğitim/Test Ayrımı ve Veri Sızıntısının Önlenmesi

4.4. Keşifsel Veri Analizi

4.5. İstatistiksel Testler

4.6. Modelleme ve Değerlendirme Metrikleri

5. Bulgular

5.1. Fiyat Dağılımı

5.2. Oda Tipine Göre Fiyat

5.3. Korelasyon Bulguları

5.4. Overfitting Analizi

5.5. Veri Miktarı Deneyi

5.6. Random Forest Modelinin İyileştirilmesi

5.7. Model Karşılaştırması

5.8. Özellik Önemleri

6. Tartışma
7. Sonuç
8. Kısıtlar ve Gelecek Çalışmalar
9. Kaynakça

ÖZET

Bu çalışmada Paris'teki Airbnb ilanlarının gecelik fiyatlarını açıklayan değişkenlerin incelenmesi ve makine öğrenmesi yöntemleriyle fiyat tahmini yapılması amaçlanmıştır. Inside Airbnb tarafından yayımlanan 16 Haziran 2026 tarihli Paris listings veri seti kullanılmıştır. Ham veri 77.679 ilan ve 90 değişkenden oluşmakta; fiyatı kullanılabilir hale getirilen 48.402 ilan analiz kapsamına alınmaktadır. Çalışmada veri temizleme, eksik değer analizi, aykırı değer incelemesi, keşifsel veri analizi, parametrik olmayan istatistiksel testler ve regresyon modellemesi birlikte yürütülmüştür.

Aykırı değerler için IQR yaklaşımı tanısal amaçla kullanılmış, ancak her istatistiksel aykırılığın veri hatası olmadığı göz önünde bulundurularak açıklayıcı değişkenlerde otomatik satır silme yapılmamıştır. Hedef fiyat için eğitim verisinden öğrenilen IQR sınırları, açıklayıcı değişkenlerde ise yalnızca aşırı uçları sınırlandıran %99 yüzdelerlik yaklaşımı tercih edilmiştir. Ön işleme adımları eğitim/test ayırımından sonra uygulanarak veri sızıntısı riski azaltılmıştır.

Linear Regression, Ridge, Lasso, ElasticNet, Decision Tree, Gradient Boosting ve Random Forest modelleri karşılaştırılmıştır. İlk kontrolsüz Decision Tree modelinde eğitim başarısının neredeyse kusursuz olmasına karşın test başarısının belirgin biçimde düşmesi overfitting göstergesi olarak değerlendirilmiştir. Model karmaşıklığı sınırlandırılmış ve Random Forest için 5 katlı çapraz doğrulamalı GridSearchCV uygulanmıştır. Nihai Random Forest modeli Train $R^2=0,7562$, Test $R^2=0,6324$, RMSE=81,71 € ve MAE=58,06 € değerlerine ulaşmıştır. Veri miktarı deneyi, eğitim verisini küçültmenin overfitting sorununu çözmediğini; tersine daha fazla eğitim verisinin test performansını iyileştirdiğini göstermiştir.

Anahtar Kelimeler: Airbnb, fiyat tahmini, regresyon, Random Forest, aykırı değer, overfitting, GridSearchCV, makine öğrenmesi

1. GİRİŞ

1.1. Problem ve Motivasyon

Kısa dönemli konaklama platformlarında fiyat, klasik otel fiyatlandırmasına göre daha heterojen bir yapı göstermektedir. Aynı şehirde bulunan iki ilan fiyatı; konum, oda tipi, konaklama kapasitesi, yatak odası ve banyo sayısı, minimum konaklama süresi, değerlendirme geçmişi ve müsaitlik gibi birçok özelliğe bağlı olarak önemli ölçüde farklılaşabilmektedir. Bu nedenle Airbnb fiyat tahmini, tek bir değişkenle açıklanabilecek basit bir regresyon problemi değildir.

Paris gibi turistik talebin yüksek, konut stokunun ve mahalle yapısının heterojen olduğu bir şehirde bu problem daha da belirgin hale gelmektedir. Çalışmanın motivasyonu yalnızca yüksek bir tahmin skoru üretmek değil; veri kalitesi, aykırı değerler ve modelin eğitim verisini ezberleme eğilimi gibi pratik veri analitiği sorunlarını da görünür kılan, savunulabilir bir modelleme süreci oluşturmaktır.

1.2. Projenin Amacı

Projenin temel amacı, Paris Airbnb ilanlarının gecelik fiyatlarını açıklayan değişkenleri incelemek ve farklı regresyon yaklaşımlarını karşılaştırarak yeni ilanlarda makul genelleme başarısı sağlayan bir model oluşturmaktır. İkinci amaç, özellikle aykırı değer işlemleri ve overfitting kontrolünün model sonucuna etkisini sistematik biçimde değerlendirmektir.

1.3. Hipotezler

Çalışmanın temel hipotezi, Paris Airbnb ilanlarında gecelik fiyatın yalnızca tek bir değişkenle değil; özellikle konaklama kapasitesi, oda ve yatak bilgileri, oda tipi ve konum gibi ilan özelliklerinin birlikte etkisiyle açıklanabileceğidir. Bu doğrultuda kapasiteyi temsil eden accommodates, bedrooms, bathrooms ve beds değişkenlerinin fiyatla pozitif ilişki göstermesi beklenmiştir. Ayrıca fiyat yapısındaki doğrusal olmayan ilişkiler nedeniyle ağaç tabanlı modellerin doğrusal regresyon modellerinden daha yüksek test performansı göstereceği; model karmaşıklığı kontrol edildiğinde ise eğitim ve test performansı arasındaki farkın azaltılabileceği öngörülmüştür.

1.4. Çalışmada Kullanılan Yöntemler

Bu hipotezleri değerlendirmek için çalışma birkaç aşamada yürütülmüştür. Öncelikle veri temizleme ve eksik değer incelemesi yapılmış, ardından IQR yaklaşımıyla aykırı gözlemler tanısal olarak değerlendirilmiştir. Fiyat dağılımı ve oda tipleri keşifsel veri analizi ile incelenmiş; normal dağılım varsayımının desteklenmemesi nedeniyle sayısal değişkenlerde Spearman korelasyonu, kategorik gruplarda ise Kruskal-Wallis testi kullanılmıştır. Modelleme aşamasında Linear Regression, Ridge, Lasso, ElasticNet, Decision Tree, Gradient Boosting ve Random Forest karşılaştırılmış; performans R^2 , MAE ve RMSE metrikleriyle değerlendirilmiştir. Overfitting kontrolü için eğitim-test farkı izlenmiş, model karmaşıklığı sınırlandırılmış ve final Random Forest modeli GridSearchCV ile ayarlanmıştır. Ayrıntılı uygulama adımları raporun Yöntem bölümünde açıklanmaktadır.

1.5. Araştırma Soruları

- Paris Airbnb ilanlarında gecelik fiyatla en güçlü ilişkili değişkenler hangileridir?
- İstatistiksel olarak aykırı görünen gözlemler hangi ölçüde gerçek veri hatasıdır ve nasıl ele alınmalıdır?
- Doğrusal modeller ile ağaç tabanlı modeller arasında tahmin başarısı bakımından nasıl bir fark vardır?
- Modeldeki overfitting eğilimi model karmaşıklığı kontrol edilerek azaltılabilir mi?
- Eğitim verisini küçültmek genelleme performansını artırmakta mıdır?
- En iyi model hangi değişkenleri fiyat tahmininde daha önemli görmektedir?

2. LİTERATÜR TARAMASI

Airbnb fiyatlarıyla ilgili çalışmalarda iki yaklaşım öne çıkmaktadır. Bir grup çalışma fiyatı etkileyen konum, kapasite, oda tipi ve ev sahibi özelliklerini açıklamaya odaklanırken; daha yeni çalışmalar bu değişkenleri kullanarak fiyat tahmini yapan makine öğrenmesi modellerini karşılaştırmaktadır. Bu proje hazırlanırken her iki gruptaki çalışmalar incelenmiş ve kullanılan değişkenler ile model seçimleri buna göre değerlendirilmiştir.

2.1. Airbnb Fiyat Belirleyicileri

Wang ve Nicolau (2017), 33 şehirde 180 binden fazla Airbnb ilanını inceleyerek ev/ilan özellikleri, ev sahibi özellikleri, olanaklar, kiralama kuralları ve çevrimiçi değerlendirmelerin fiyat üzerinde farklı etkileri olduğunu göstermiştir [2]. Gibbs ve arkadaşları (2018) hedonic pricing yaklaşımıyla fiziksel özelliklerin, konumun ve ev sahibi özelliklerinin fiyatı anlamlı biçimde etkilediğini raporlamıştır [3]. Avrupa şehirlerine odaklanan Gyódi ve Nawaro (2021) ise fiyatların mekânsal bağımlılık gösterdiğini; büyüklük, kalite ve konumun yanında turistik çekicilik ve erişilebilirliğin de önemli fiyat belirleyicileri olduğunu ortaya koymuştur [4].

Bu sonuçlar, projede kullanılan accommodates, bedrooms, bathrooms, room_type, neighbourhood ve koordinat bilgilerinin fiyatla ilişkisini incelemek için anlamlı değişkenler olduğunu desteklemektedir. Aynı zamanda konum bilgisinin yalnızca mahalle adıyla sınırlı kalmaması gerektiğini de göstermektedir; turistik noktalara veya toplu taşımaya uzaklık gibi özellikler ileride modele eklenebilir.

2.2. Makine Öğrenmesi ile Fiyat Tahmini

Son yıllarda Airbnb fiyat tahmininde doğrusal regresyonların yanında Decision Tree, Random Forest, Gradient Boosting, XGBoost, CatBoost ve yapay sinir ağları gibi yöntemler daha sık kullanılmaktadır. Lektorov, Abdelfattah ve Joshi (2023), New York Airbnb verilerinde çeşitli makine öğrenmesi modellerini karşılaştırmış ve ağaç tabanlı yöntemlerin güçlü performans verdiğini göstermiştir [5]. Tang, Cheng ve Zhang (2024) Sydney verisinde on farklı algoritmayı karşılaştırmış; en önemli fiyat belirleyicileri arasında maksimum misafir sayısı ve yatak odası sayısını bulmuştur [6].

Camatti ve arkadaşları (2024), Hollanda Airbnb verisinde geleneksel doğrusal yöntemlerle yapay zekâ tabanlı yöntemleri karşılaştırmış; Random Forest gibi doğrusal olmayan yöntemlerin genel tahmin performansında daha güçlü olabildiğini, buna karşılık doğrusal modellerin yorumlanabilirlik açısından yararlı kaldığını vurgulamıştır [7]. Bu sonuçlar, bu projede hem doğrusal modellerin hem de ağaç tabanlı modellerin aynı değerlendirme çerçevesinde karşılaştırılması yaklaşımını desteklemektedir.

2.3. Aykırı Değer ve Genelleme Problemi

Aykırı değer analizi keşifsel veri analizinin temel parçalarından biridir. Tukey'nin (1977) kutu grafiği ve çeyrekler arası açıklık yaklaşımı, uç gözlemlerin sistematik biçimde belirlenmesinde klasik bir çerçeve sunmaktadır [8]. Bununla birlikte istatistiksel olarak uç olan bir gözlem her zaman hatalı değildir. Airbnb gibi heterojen pazarlarda lüks, çok yüksek kapasiteli veya alışılmadık konaklama kurallarına sahip gerçek ilanlar dağılımın uçlarında doğal olarak yer alabilir.

Modelleme tarafında Decision Tree'lerin yüksek varyans nedeniyle eğitim verisine aşırı uyum gösterebilmesi bilinen bir sorundur. Breiman'ın Random Forest yaklaşımı, çok sayıda ağacın rastgele örneklem ve özellik alt kümeleri üzerinde kurulup ortalanmasıyla varyansı azaltmayı ve genelleme performansını iyileştirmeyi amaçlar [9]. Bu projede de model başarısı yalnızca eğitim skoru ile değil, eğitim-test farkı ve çapraz doğrulama sonuçlarıyla birlikte değerlendirilmiştir.

2.4. Literatürün Projeye Yansıması

Literatürdeki çalışmalar incelendiğinde kapasite ve konum değişkenlerinin sık kullanıldığı, ağaç tabanlı modellerin de fiyat tahmininde güçlü sonuçlar verebildiği görülmüştür. Bu projede benzer değişkenler Paris verisi üzerinde test edilmiş ve doğrusal modellerle ağaç tabanlı modeller karşılaştırılmıştır. Çalışmada ayrıca ders sırasında özellikle üzerinde durulan iki noktaya, aykırı değerlerin nasıl ele alındığına ve modelin overfitting eğilimine, ayrı olarak odaklanılmıştır.

3. VERİ SETİ VE KULLANILAN ARAÇLAR

3.1. Veri Seti

Veri kaynağı olarak Inside Airbnb tarafından yayımlanan Paris'e ait 16 Haziran 2026 tarihli detaylı listings veri seti kullanılmıştır [1]. Ham veri 77.679 satır ve 90 sütundan oluşmaktadır. Tam satır düzeyinde tekrar bulunmamıştır. Price alanı sayısal biçime dönüştürüldükten ve fiyatı eksik ya da sıfırdan küçük/eşit kayıtlar çıkarıldıktan sonra 48.402 ilan analiz için kullanılabilir hale gelmiştir.

Temizleme öncesinde reviews_per_month ve review_scores_rating değişkenlerinde yaklaşık %17, bedrooms değişkeninde %16 ve bathrooms değişkeninde %12 oranında eksik değer bulunmaktadır. Bu eksikler tüm veri üzerinden tek seferde doldurulmamış, modelleme aşamasında eğitim verisinden öğrenilen değerlerle tamamlanmıştır.

3.2. Kullanılan Değişkenler

Değişken	Açıklama
price_eur	Hedef değişken; gecelik fiyat (€)
neighbourhood_cleansed	İlanın bulunduğu Paris mahallesi/bölgesi
latitude / longitude	Coğrafi konum koordinatları
room_type	Konaklama türü
accommodates	Maksimum misafir kapasitesi
bedrooms / bathrooms / beds	Yatak odası, banyo ve yatak bilgileri
number_of_reviews	Toplam yorum sayısı
reviews_per_month	Aylık ortalama yorum sayısı
review_scores_rating	Ortalama değerlendirme puanı
minimum_nights	Minimum konaklama süresi
availability_365	Yıl içindeki müsait gün sayısı

3.3. Kullanılan Teknolojiler

Katman	Araç / Kütüphane	Amaç
Geliştirme	Python, Google Colab	Analiz ve model geliştirme
Veri İşleme	pandas, NumPy	Temizleme, dönüşüm ve veri hazırlama
Görselleştirme	Matplotlib, Seaborn	EDA ve model sonuçlarının görselleştirilmesi
İstatistik	SciPy	Shapiro-Wilk ve Kruskal-Wallis testleri
Modelleme	scikit-learn	Regresyon, preprocessing, cross-validation, GridSearchCV

Anomali Analizi	IQR / ders notlarındaki anomali yaklaşımı	Uç gözlemlerin tanısal incelenmesi
-----------------	---	------------------------------------

4. YÖNTEM


4.1. Veri Temizleme ve Eksik Değerler

Analiz akışı veri yükleme, temel temizlik, eksik değer analizi, aykırı değer incelemesi, EDA, istatistiksel testler, eğitim/test ayrımı, ön işleme, modelleme, hiperparametre optimizasyonu ve sonuçların karşılaştırılması adımlarından oluşmuştur. Sayısal değişkenlerde medyan, kategorik değişkenlerde en sık görülen değer kullanılmış; ancak bu değerler yalnızca eğitim kümelerinden öğrenilmiştir.

4.2. Aykırı Değer Analizi

Sayısal değişkenlerde ilk tanısal araç olarak IQR yöntemi kullanılmıştır. Klasik alt ve üst sınırlar $Q1-1,5 \times IQR$ ve $Q3+1,5 \times IQR$ olarak hesaplanmıştır. Ancak Airbnb verisinde yüksek kapasiteli veya çok banyolu gerçek ilanların bulunması nedeniyle IQR ile işaretlenen her gözlem otomatik olarak silinmemiştir.

Değişken	IQR Outlier (%)	Gözlenen maksimum
price_eur	7,85	97.003,05 €
accommodates	3,76	16
bedrooms	3,02	33
bathrooms	22,32	42
beds	9,31	32
number_of_reviews	9,00	4.589
reviews_per_month	5,64	55,49
minimum_nights	15,17	365
availability_365	0,00	365



Şekil 1: Sayısal değişkenlerde IQR kuralına göre aykırı gözlem oranları

Bathrooms değişkeninde $Q1=Q3=1$ olduğundan IQR sıfırdır. Bu nedenle 1'den farklı çok sayıda geçerli gözlem aykırı olarak işaretlenmektedir. Bu örnek, otomatik IQR silmenin veri yapısını bozabileceğini açık biçimde göstermiştir. Modelleme aşamasında hedef fiyat için yalnızca eğitim verisinden öğrenilen IQR kapsamı kullanılmış; açıklayıcı değişkenlerde ise daha konservatif olarak eğitim verisinin %99 yüzdeline sınırlanmış ve aşırı uç değerlerin etkisi sınırlandırılmıştır.

4.3. Eğitim/Test Ayırımı ve Veri Sızıntısının Önlenmesi

Veri %80 eğitim ve %20 test olacak şekilde ayrılmıştır. Eksik değer doldurma, aykırı değer eşikleri, kategorik kodlama ve ölçekleme parametreleri test setine bakılmadan eğitim verisinden öğrenilmiştir. Kategorik değişkenler one-hot encoding ile dönüştürülmüş; doğrusal modellerde sayısal değişkenler standardize edilirken ağaç tabanlı modeller ölçekleme olmadan eğitilmiştir. Bu tasarım, test verisinin preprocessing kararlarına sızmasını önlemek için tercih edilmiştir.

4.4. Keşifsel Veri Analizi

EDA aşamasında fiyat dağılımı, oda tiplerine göre medyan fiyatlar, sayısal değişkenlerin dağılımları ve Spearman korelasyonları incelenmiştir. Fiyat dağılımının belirgin sağ çarpık olması nedeniyle ortalama ile medyan birlikte değerlendirilmiş; doğrusal ilişki varsayımına daha az bağımlı olması nedeniyle korelasyon analizinde Spearman katsayısı kullanılmıştır.

4.5. İstatistiksel Testler

Fiyat değişkeninin normal dağılıma uygunluğu Shapiro-Wilk testi ile 5.000 gözlemlik örneklem üzerinde kontrol edilmiş ve normal dağılım varsayımı desteklenmemiştir. Bu nedenle sayısal ilişkiler için Spearman korelasyonu, oda tipi ve mahalle gibi kategorik gruplar için Kruskal-Wallis testi kullanılmıştır. Büyük örneklemde p-değerlerinin

çok küçük farklarda dahi anlamlı olabileceği göz önünde bulundurularak istatistiksel anlamlılık, grafiksel bulgular ve ilişki büyüklüğü ile birlikte yorumlanmıştır.


4.6. Modelleme ve Değerlendirme Metrikleri

Karşılaştırma için Linear Regression, Ridge, Lasso, ElasticNet, Decision Tree, Gradient Boosting ve Random Forest modelleri kullanılmıştır. Performans R^2 , MAE ve RMSE ile ölçülmüştür. R^2 açıklanan varyans oranını; MAE tahminlerin gerçek fiyatlardan ortalama mutlak sapmasını; RMSE ise büyük hataları daha güçlü cezalandıran hata ölçüsünü göstermektedir.

5. BULGULAR

5.1. Fiyat Dağılımı

Fiyat dağılımı belirgin biçimde sağa çarpıktır. Analiz verisinde medyan gecelik fiyat yaklaşık 205,50 €, ortalama ise 321,23 € düzeyindedir. Ortalama ile medyan arasındaki bu fark, az sayıdaki yüksek fiyatlı ilanların dağılımın sağ kuyruğunu uzattığını göstermektedir.




Şekil 2: Paris Airbnb gecelik fiyat dağılımı (görselleştirme 0-1000 € aralığı)

Şekil 2’de ilanların büyük bölümünün düşük ve orta fiyat aralığında toplandığı, fiyat yükseldikçe ilan sayısının belirgin biçimde azaldığı görülmektedir. Sağ tarafta uzayan kuyruk, yüksek fiyatlı az sayıdaki ilanın ortalamayı yukarı çektiğini ve fiyat değişkeninde aykırı değer incelemesinin neden gerekli olduğunu desteklemektedir.

5.2. Oda Tipine Göre Fiyat

Oda tipleri arasında belirgin fiyat farklılıkları vardır. Hotel room kategorisi en yüksek medyan fiyata sahipken, entire home/apartment ikinci sırada yer almakta; private room ve shared room kategorilerinde medyan fiyat daha düşüktür. Kruskal-Wallis sonucu da oda tipi grupları arasındaki fiyat farklarının istatistiksel olarak anlamlı olduğunu desteklemektedir.




Şekil 3: Oda tiplerine göre medyan gecelik fiyat

Şekil 3, oda tipinin fiyat üzerinde belirgin bir ayrıştırıcı olduğunu göstermektedir. Hotel room ve entire home/apartment kategorilerindeki medyan fiyatların private room ve shared room kategorilerinden daha yüksek olması, konaklama türünün modelde dikkate alınması gereken önemli bir kategorik değişken olduğunu göstermektedir.

5.3. Korelasyon Bulguları

Fiyat ile en belirgin pozitif Spearman ilişkileri accommodates ($p \approx 0,60$), beds ($p \approx 0,54$), bedrooms ($p \approx 0,53$) ve bathrooms ($p \approx 0,43$) değişkenlerinde görülmüştür. Minimum_nights ile fiyat arasında orta düzeyde negatif ilişki ($p \approx -0,33$) bulunmaktadır. Yorum sayısı ve değerlendirme puanı gibi değişkenlerin tek başına fiyatla ilişkisi daha zayıftır.



Şekil 4: Sayısal değişkenler için Spearman korelasyon matrisi


Şekil 4'te fiyatla en güçlü pozitif ilişkilerin accommodates, beds ve bedrooms değişkenlerinde toplandığı görülmektedir. Buna karşılık minimum_nights fiyatla negatif yönlü ilişki göstermektedir. Matris ayrıca bazı kapasite değişkenlerinin kendi aralarında da yüksek korelasyona sahip olduğunu gösterdiği için sonuçlar tek bir değişkene dayanarak değil, model içindeki ortak etkileriyle birlikte değerlendirilmiştir.

5.4. Overfitting Analizi

İlk kontrolsüz Decision Tree modeli eğitim verisinde R^2 değerini neredeyse 1,00 seviyesine taşımış, buna karşın test performansı belirgin biçimde daha düşük kalmıştır. Bu durum modelin genellenebilir örüntülerden çok eğitim verisinin ayrıntılarını öğrendiğini göstermiştir. max_depth, min_samples_split ve min_samples_leaf gibi karmaşıklık parametreleri sınırlandırıldığında eğitim-test farkı belirgin biçimde küçülmüştür. Bu nedenle daha düşük eğitim skoru, tek başına başarısızlık olarak değil, genelleme lehine bir denge olarak değerlendirilmiştir.

5.5. Veri Miktarı Deneyi

Overfitting probleminin veri hacminden kaynaklanıp kaynaklanmadığını sınamak için test seti sabit tutulmuş ve aynı Random Forest yaklaşımı eğitim verisinin %10, %25, %50, %75 ve %100'ü ile tekrar eğitilmiştir. Test R^2 değeri yaklaşık 0,584'ten 0,631'e yükselmiş; daha az veri kullanmak genelleme başarısını artırmamıştır.



Şekil 5: Eğitim veri miktarının Random Forest performansına etkisi

Şekil 5'te eğitim verisi arttıkça Test R^2 değerinin düzenli biçimde yükseldiği, Train R^2 değerinin ise büyük ölçüde sabit kaldığı görülmektedir. Bu sonuç, daha az veri kullanmanın overfitting sorununu çözmediğini; aksine daha fazla gözlemin modelin genelleme performansına katkı sağladığını göstermektedir.

Eğitim verisi	Train R^2	Test R^2
%10	0,7617	0,5835
%25	0,7656	0,6052
%50	0,7633	0,6179
%75	0,7586	0,6267
%100	0,7553	0,6313


5.6. Random Forest Modelinin İyileştirilmesi

Random Forest için 5 katlı çapraz doğrulamalı GridSearchCV kullanılmıştır. Hesaplama maliyetini yönetilebilir tutmak için arama yalnızca eğitim setinden seçilen 10.000 gözlemlik sabit bir alt kümede gerçekleştirilmiş; test seti hiperparametre seçiminde kullanılmamıştır. Seçilen parametrelerle final model daha sonra tüm eğitim verisi üzerinde yeniden eğitilmiştir.

Parametre	Final değer
n_estimators	80
max_depth	15
min_samples_split	12
min_samples_leaf	6
max_features	0,7

5.7. Model Karşılaştırması


Model	Train R ²	Test R ²	RMSE (€)	MAE (€)
Linear Regression	0,5590	0,5507	90,33	66,31
Ridge	0,5590	0,5507	90,33	66,31
Lasso	0,5586	0,5503	90,36	66,30
ElasticNet	0,5586	0,5504	90,36	66,32
Decision Tree	0,5899	0,5468	90,72	64,98
Gradient Boosting	0,6372	0,6179	83,30	59,78
Random Forest	0,7562	0,6324	81,71	58,06



Şekil 6: Regresyon modellerinin Test R² değerleri

Random Forest en yüksek Test R² ve en düşük RMSE/MAE değerlerini vermiştir. MAE=58,06 €, model tahminlerinin gerçek gecelik fiyatlardan ortalama mutlak olarak yaklaşık 58 € saptığı anlamına gelmektedir. Train R² ile Test R² arasındaki yaklaşık 0,124'lük fark, overfitting'in tamamen ortadan kalkmadığını; ancak ilk kontrolsüz ağaç modeline göre belirgin biçimde azaltıldığını göstermektedir.

5.8. Özellik Önemleri



Şekil 7: Final Random Forest modelinde özellik önemleri

Final modelde accommodates, minimum_nights ve bedrooms en yüksek önem değerlerine sahip değişkenler arasındadır; latitude ve longitude gibi konum değişkenleri de üst sıralarda yer almaktadır. Minimum_nights değişkeninin basit korelasyonda negatif ilişki göstermesine rağmen model içinde yüksek önem alması, doğrusal olmayan ilişkilerin ve değişken etkileşimlerinin önemini göstermektedir.

6. TARTIŞMA

Bulguların önemli bir bölümü Airbnb fiyatlandırma literatürüyle uyumludur. Kapasite ve yatak odası sayısının hem korelasyon analizinde hem Random Forest özellik öneminde öne çıkması, Tang ve arkadaşlarının (2024) maksimum misafir sayısı ve yatak odası sayısını temel belirleyiciler arasında göstermesiyle paraleldir [6]. Wang ve Nicolau'nun çok şehirli çalışması ile Gibbs ve arkadaşlarının hedonic pricing analizi de fiziksel ilan özelliklerinin fiyat üzerindeki önemini desteklemektedir [2][3].

Konum değişkenlerinin modelde anlamlı önem taşıması da Avrupa şehirlerinde mekânsal bağımlılığın ve turistik erişilebilirliğin fiyat üzerindeki rolünü gösteren Gyódi ve Nawaro (2021) ile tutarlıdır [4]. Buna rağmen bu projede yalnızca mahalle ve koordinat bilgileri kullanılmıştır. Louvre, Eyfel Kulesi, metro istasyonları veya turistik yoğunluk gibi mekânsal özelliklerin eklenmesi özellikle Paris için tahmin gücünü artırabilir.

Model karşılaştırmasında doğrusal modellerin yaklaşık 0,55 Test R^2 seviyesinde birbirine çok yakın sonuç vermesi, yalnızca regularization uygulamanın doğrusal olmayan fiyat yapısını yakalamaya yetmediğini düşündürmektedir. Gradient Boosting ve Random Forest'in daha yüksek test performansı, doğrusal olmayan ilişkilerin ve değişken etkileşimlerinin önemli olduğuna işaret etmektedir. Bu bulgu, Airbnb fiyat tahmininde ağaç tabanlı yöntemlerin güçlü sonuçlar verebildiğini gösteren güncel çalışmalarla uyumludur [5][7].

Aykırı değer yaklaşımı çalışmanın metodolojik açıdan en kritik kararlarından biridir. Bathrooms değişkenindeki IQR=0 örneği, mekanik bir outlier temizliğinin gerçek ve anlamlı ilanları veri setinden çıkarabileceğini göstermiştir. Bu nedenle tanışal IQR analizi ile modelleme için kullanılan konservatif sınırlandırma birbirinden ayrılmıştır. Böylece hem uç gözlemlerin etkisi kontrol edilmiş hem de veri setinin doğal heterojenliği tamamen ortadan kaldırılmamıştır.

Overfitting açısından final model kusursuz değildir. Train $R^2=0,7562$ ve Test $R^2=0,6324$ arasındaki fark hâlâ dikkate değerdir. Ancak amaç eğitim-test farkını sıfırlamak değil, test başarısını korurken model varyansını kabul edilebilir düzeyde tutmaktır. Veri küçültme deneyinde daha az eğitim verisinin daha kötü test başarısı üretmesi de problemin veri hacminden çok model karmaşıklığı ve veri yapısıyla ilişkili olduğunu desteklemektedir.

7. SONUÇ

Bu projede Paris Airbnb ilanlarının gecelik fiyatları uçtan uca bir veri analitiği süreciyle incelenmiştir. Ham 77.679 ilandan fiyatı kullanılabilir 48.402 ilan elde edilmiş; veri temizleme, eksik değer analizi, aykırı değer incelemesi, EDA, istatistiksel testler ve yedi farklı regresyon yaklaşımı aynı çalışma içinde karşılaştırılmıştır.

Fiyat dağılımının sağa çarpık olduğu, fiziksel kapasiteyi temsil eden accommodates, beds, bedrooms ve bathrooms değişkenlerinin fiyatla en güçlü pozitif ilişkilere sahip olduğu görülmüştür. Oda tipi ve mahalle grupları arasında fiyat açısından anlamlı farklılıklar bulunmaktadır. Aykırı değer analizinde her istatistiksel uç gözlemin veri hatası olmadığı gösterilmiş; bu nedenle IQR tanışal amaçla kullanılırken modelleme aşamasında daha kontrollü eşikler tercih edilmiştir.

Modelleme sonucunda Random Forest en dengeli ve en başarılı yöntem olmuştur. Final model Test $R^2=0,6324$, RMSE=81,71 € ve MAE=58,06 € değerlerine ulaşmıştır. Başlangıçtaki belirgin overfitting, model karmaşıklığının sınırlandırılması ve çapraz doğrulama ile azaltılmıştır. Eğitim verisini küçültmek performansı iyileştirmemiş; aksine daha fazla veri test başarısına katkı sağlamıştır. Sonuç olarak bu veri setinde model başarısını artıran temel yaklaşım veri azaltmak değil, preprocessing kararlarını kontrollü yapmak ve model karmaşıklığını doğru yönetmek olmuştur.

8. KISITLAR VE GELECEK ÇALIŞMALAR

- Çalışma yalnızca Paris ilanlarını ve 16 Haziran 2026 tarihli veri kesitini temsil etmektedir; farklı şehir ve dönemlere doğrudan genellenmemelidir.
- Airbnb fiyatları sezon, tatil, etkinlik, hafta içi/hafta sonu ve rezervasyon tarihine göre değişebilmektedir. Tek kesitli listings verisi bu dinamikleri tam olarak yansıtmamaktadır.
- Çok yüksek fiyatlı ilanların bir kısmı gerçek lüks ilanlardır. Bu nedenle outlier işlemleri model kapsamını istikrarlı hale getirmek içindir; tüm pazarın uç segmentlerini temsil ettiği varsayılmamalıdır.
- Turistik noktalara, metro istasyonlarına ve şehir merkezine uzaklık gibi daha ayrıntılı mekânsal değişkenler modele eklenebilir.
- İlan açıklaması, yorum metinleri, fotoğraf kalitesi, amenities ayrıntıları ve ev sahibi özellikleri gibi ek değişkenler tahmin gücünü artırabilir.
- Random Forest'ta bir miktar eğitim-test farkı sürmektedir. Daha geniş hiperparametre araması, XGBoost/CatBoost/LightGBM gibi boosting yöntemleri ve nested cross-validation ileride değerlendirilebilir.
- Modelin farklı tarihli Paris veri kesitlerinde veya başka Avrupa şehirlerinde dış doğrulaması yapılarak genellenebilirliği ayrıca test edilebilir.

9. KAYNAKÇA

- [1] Inside Airbnb. (2026). Paris detailed listings data, 16 June 2026. Inside Airbnb.
- [2] Wang, D., & Nicolau, J. L. (2017). Price determinants of sharing economy based accommodation rental: A study of listings from 33 cities on Airbnb.com. *International Journal of Hospitality Management*, 62, 120-131. <https://doi.org/10.1016/j.ijhm.2016.12.007>
- [3] Gibbs, C., Guttentag, D., Gretzel, U., Morton, J., & Goodwill, A. (2018). Pricing in the sharing economy: A hedonic pricing model applied to Airbnb listings. *Journal of Travel & Tourism Marketing*, 35(1), 46-56. <https://doi.org/10.1080/10548408.2017.1308292>
- [4] Gyódi, K., & Nawaro, Ł. (2021). Determinants of Airbnb prices in European cities: A spatial econometrics approach. *Tourism Management*, 86, 104319. <https://doi.org/10.1016/j.tourman.2021.104319>
- [5] Lektorov, A., Abdelfattah, E., & Joshi, S. (2023). Airbnb rental price prediction using machine learning models. 2023 IEEE 13th Annual Computing and Communication Workshop and Conference (CCWC). <https://doi.org/10.1109/CCWC57344.2023.10099266>
- [6] Tang, J., Cheng, J., & Zhang, M. (2024). Forecasting Airbnb prices through machine learning. *Managerial and Decision Economics*, 45(1), 148-160. <https://doi.org/10.1002/mde.3985>
- [7] Camatti, N., di Tollo, G., Filograsso, G., et al. (2024). Predicting Airbnb pricing: A comparative analysis of artificial intelligence and traditional approaches. *Computational Management Science*, 21, 30. <https://doi.org/10.1007/s10287-024-00511-4>
- [8] Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.
- [9] Breiman, L. (2001). Random Forests. *Machine Learning*, 45, 5-32. <https://doi.org/10.1023/A:1010933404324>
- [10] Voltes-Dorta, A., & Sánchez-Medina, A. (2020). Drivers of Airbnb prices according to property/room type, season and location: A regression approach. *Journal of Hospitality and Tourism Management*, 45, 266-275. <https://doi.org/10.1016/j.jhtm.2020.08.015>
- [11] Scikit-learn Developers. (2026). Scikit-learn documentation: RandomForestRegressor, preprocessing, model selection and GridSearchCV.
- [12] SoftITo Veri Analitiği ders notları. Keşifsel veri analizi, Decision Tree, Random Forest, Ridge-Lasso-ElasticNet, anomali tespiti ve model değerlendirme notları.